

Introdução ao Cálculo Diferencial Integral para Ciência de Dados

Prof. Wagner Hugo Bonat

Curso de Especialização em
Data Science & Big Data
Universidade Federal do Paraná

7 de março de 2019



Conteúdo

Conteúdo

1. Funções, limites e continuidade.
2. Derivada
 - 2.1 Definição e aplicações;
 - 2.2 Regra da cadeia;
 - 2.3 Máximos e mínimos.
 - 2.4 Funções de duas ou mais variáveis independentes.
 - 2.5 Gradiente e Hessiano.
 - 2.6 Expansão em Série de Taylor.
3. Integrais
 - 3.1 Definição;
 - 3.2 Soma de Riemann;
 - 3.3 Teorema fundamental do cálculo;
 - 3.4 Propriedades;
 - 3.5 Regras de integração.



Funções, limites e continuidade.

Funções

- ▶ Definição 1 - Uma **função** escrita como $y = f(x)$ associa um número y a cada valor de x .
- ▶ x é chamada de variável **independente**.
- ▶ **Domínio de $f(x)$** é a faixa de valores que x pode assumir.
- ▶ y é chamada de variável **dependente**.
- ▶ **Imagem de $f(x)$** é a faixa de valores que y pode assumir.
- ▶ Resumindo temos,


$$\begin{array}{ccc} x \in D & \xrightarrow{\quad} & f(x) \xrightarrow{\quad} y \in I \\ \text{Independente} & & \text{Dependente} \end{array}$$

- ▶ O **domínio** e **imagem** de uma função são intervalos.
- ▶ Tipos de intervalos:
 - ▶ Intervalo aberto **não contêm** as extremidades: Notação (a, b) .
 - ▶ Intervalo fechado **contêm** as extremidades: Notação $[a, b]$.

Funções: Intuição



Funções: Intuição



► Exemplos:


1. Preço do seguro do seu carro;
2. Concessão de crédito;
3. Detecção de potenciais clientes;
4. Detecção de software/operações maliciosas;
5. etc.

Exemplo

- Considere a função $y = x^2$

```
fx = function(x) {  
  out <- x^2  
  return(out)  
}
```

- Gráfico da função



Funções parametrizadas


- ▶ Definição 2 - **Parâmetro** é uma quantidade conhecida que indexa ou parametriza uma determinada função.
- ▶ Em geral os parâmetros mudam o comportamento da função e descrevem quantidades de interesse.
- ▶ Notação: $y = f(x; \theta)$, onde θ denota o parâmetro.
- ▶ O conjunto de valores que θ pode assumir é chamado de espaço paramétrico. Notação $\theta \in \Theta$.

Exemplo: Função parametrizada

- ▶ Exemplo: $y = (x - \theta)^2$

```
fx = function(x, theta) {  
  out <- (x - theta)^2  
  return(out)  
}
```

- ▶ Gráfico da função.



Funções com vários parâmetros

- ▶ Em geral uma função pode ter vários parâmetros.
- ▶ O ideal é que cada parâmetro controle um aspecto da função.
- ▶ Exemplo: $y = f(x; \theta_1, \theta_2)$ ou mais geral $y = f(x; \theta)$, onde θ é um vetor de parâmetros.
- ▶ Função com dois parâmetros:


$$y = \frac{(x - \theta_1)^2}{\theta_2}.$$

Funções com múltiplos parâmetros

► Função em R.


```
fx = function(x, theta) {  
  out <- ((x - theta[1])^2)/theta[2]  
  return(out)  
}
```

► Gráfico da função para diferentes valores dos parâmetros.



Funções e suas formas


Linear Function




Quadric Function




Cubic Function



Sine Function




Cosine Function



Rational Function



Exponential Function



Logarithmic Function



Limite de uma função

- ▶ Definição 3 - Se uma função $f(x)$ se aproxima de um número L conforme x tende a um número a vindo da direita ou da esquerda, dizemos que o limite de $f(x)$ tende a L quando x tende a a .

- ▶ Notação


$$\lim_{x \rightarrow a} f(x) = f(a) = L.$$

- ▶ O limite pode não existir.
- ▶ Se o limite de uma função existe ele é único.

Limite de funções - Exemplo 1

- Considere o limite

$$\lim_{x \rightarrow 1} (x + 1) = 2.$$



Limite de funções - Exemplo 2


- Considere o limite

$$\lim_{x \rightarrow 1} \frac{x^2 - 1}{x - 1} = ?$$

```
fx <- function(x) {  
  out <- (x^2 - 1)/(x - 1)  
  return(out)  
}  
fx(x = 1)  
## [1] NaN
```


Limite de funções - Exemplo 2

- Graficamente temos



Limite de funções - Exemplo 2

- Note que

$$\lim_{x \rightarrow 1} \frac{x^2 - 1}{x - 1} = \lim_{x \rightarrow 1} \frac{(x + 1)(x - 1)}{x - 1} = \lim_{x \rightarrow 1} (x + 1) = 2.$$

- **Definição intuitiva:** O limite de uma função é o valor que achamos natural para ela em um determinado ponto.


Continuidade de uma função

- ▶ Definição 4 - Dizemos que uma função é **contínua** em $x = a$ se três condições forem satisfeitas: $f(a)$ existe, $\lim_{x \rightarrow a} f(x)$ existe e $\lim_{x \rightarrow a} f(x) = f(a)$.
- ▶ Continuidade significa que pequenas variações na variável independente levam a pequenas variações na variável dependente.
- ▶ **Teorema do valor intermediário:** Se a função $f(x)$ é contínua no intervalo fechado $[a, b]$, então existe pelo menos um número c em $[a, b]$ tal que $f(c) = M$.
- ▶ Implicação: Se $f(x)$ é contínua seu gráfico não contém salto vertical.
- ▶ Em geral podemos pensar em funções contínuas como sendo funções suaves.

Exemplo - Função não contínua

- Considere a função não contínua em 0.

$$\lim_{x \rightarrow 0} \frac{|x|}{x} = \begin{cases} -1 & x < 0 \\ 1 & x > 0. \end{cases}$$





Derivadas

Derivada de uma função

- Definição 5 - Derivada ordinária, derivada primeira, ou simplesmente, derivada de uma função $y = f(x)$ em um ponto $x = a$ no domínio de f é representada por $\frac{dy}{dx}$, y' , $\frac{df}{dx}$ ou $f'(a)$ é o valor

$$\frac{dy}{dx}|_{x=a} = f'(a) = \lim_{h \rightarrow 0} \frac{f(a+h) - f(a)}{h}.$$

Exemplo: Derivada de uma função

- Obtenha a derivada de $f(x) = -x^2$.

$$\begin{aligned}f'(x) &= \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h} \\&= \lim_{h \rightarrow 0} \frac{-(x+h)^2 - (-x^2)}{h} \\&= \lim_{h \rightarrow 0} \frac{-(x^2 + 2xh + h^2) + x^2}{h} \\&= \lim_{h \rightarrow 0} \frac{-x^2 - 2xh - h^2}{h} = \frac{-2xh - h^2}{h} \\&= \lim_{h \rightarrow 0} -2x - h = -2x.\end{aligned}$$

Interpretação da derivada

- ▶ Taxa de mudança instantânea.
- ▶ No limite quando $x \rightarrow a$ a derivada é a reta tangente ao ponto $(a, f(a))$.
- ▶ A reta tangente ao ponto a tem equação dada por $y - f(a) = f'(a)(x - a)$.
- ▶ Exemplo: Obtenha a reta tangente a $f(x)$ nos pontos $a = 2$ e $a = -2$.
- ▶ Temos $f(x = 2) = -4$ e $f'(x = 2) = -4$, assim

$$y - f(x = 2) = f'(x = 2)(x - 2)$$

$$y - (-4) = -4(x - 2)$$

$$y + 4 = -4x + 8$$


$$y = 4 - 4x$$

Exemplo - Reta tangente a $f(x)$

► $f(x)$ e $f'(x)$.

```
fx <- function(x) {  
  out <- - x^2  
  return(out)  
}  
  
f_prime <- function(x) {  
  out <- -2*x  
  return(out)  
}  
  
# Equação da reta y = a + b*x  
intercept = (fx(x = 2) - f_prime(x = 2)*2)  
intercept  
  
## [1] 4  
  
slope <- f_prime(x = 2)  
slope  
  
## [1] -4
```

Exemplo - Reta tangente a $f(x)$



Exemplo - Reta tangente a $f(x)$: Código

```
par(mar=c(2.6, 2.8, 1.2, 0.5), mgp = c(1.6, 0.6, 0))
x <- seq(-5, 5, l = 11)
plot(fx(x) ~ x, type = "l", ylim = c(-25, 4))
dev_values <- seq(0.5, 5, l = 100)
lines(dev_values, c(intercept + slope*dev_values))
a = (fx(x = -2) - f_prime(x = -2)*-2)
b = f_prime(x = -2)
dev_values <- seq(-5, -0.5, l = 100)
lines(dev_values, c(a + b*dev_values))
points(-2, -4)
points(2, -4)
```

Regras de derivação

- ▶ Seja $n \neq 0$ um natural. São válidas as fórmulas de derivação:

1. Se $f(x) = c$ então $f'(x) = 0$.
2. Se $f(x) = x^n$ então $f'(x) = nx^{n-1}$.
3. Se $f(x) = x^{-n}$ então $f'(x) = -nx^{-n-1}$.
4. Se $f(x) = x^{1/n}$ então $f'(x) = \frac{1}{n}x^{\frac{1}{n}-1}$.

- ▶ Derivada de funções especiais.

1. Se $f(x) = \exp(x)$ então $f'(x) = \exp(x)$.
2. Se $f(x) = \ln(x)$ então $f'(x) = \frac{1}{x}, x > 0$.

- ▶ Sejam $f(x)$ e $g(x)$ deriváveis em x e seja c uma constante. Então as funções $f(x) + g(x)$, $cf(x)$ e $f(x) \cdot g(x)$ são deriváveis em x e têm-se

1. $(f + g)' = f'(x) + g'(x)$.
2. $(cf)'(x) = cf'(x)$.
3. $(f \cdot g)'(x) = f'(x)g(x) + f(x)g'(x)$.

Regras de derivação

- ▶ Regra da cadeia: Sejam $y = f(x)$ e $x = g(t)$ duas funções deriváveis, com $I \in D_f$. A função composta $h(t) = f(g(t))$ é derivável, sendo

$$h'(t) = f'(g(t))g'(t), t \in D_g.$$

- ▶ Existe uma infinidade de fórmulas de derivação.
- ▶ Na prática é comum usar um software de matemática simbólica como o wxMaxima.
- ▶ Em R as funções `deriv()` e `deriv3()`.
- ▶ Exemplos.

Por que derivadas são importantes?

- ▶ Derivada é a inclinação (slope) da reta tangente à curva $y = f(x)$.
- ▶ **Obtenção de máximo ou mínimo de uma função (fundamental !!!).**
- ▶ O **máximo** de uma função $f(x)$ é o valor x_n tal que, $f(x_n) \geq f(x), \forall x \in D$.
- ▶ O **mínimo** de uma função $f(x)$ é o valor x_1 tal que, $f(x_1) \leq f(x), \forall x \in D$.

Problema: Redução de dados

- ▶ Suponha que temos um conjunto de observações y_i para $i = 1, \dots, n$. Queremos resumir a informação contida em y_i em um único número, digamos μ .
- ▶ Problema: Como encontrar μ ?

Problema: Redução de dados

- ▶ Suponha que temos um conjunto de observações y_i para $i = 1, \dots, n$. Queremos resumir a informação contida em y_i em um único número, digamos μ .
- ▶ Problema: Como encontrar μ ?
- ▶ Solução: Encontrar o valor μ , tal que $f(\mu) = \sum_{i=1}^n (y_i - \mu)^2$, seja a menor possível.
- ▶ Note que uma vez que temos os números observados y_i a única quantidade desconhecida é μ .
- ▶ Note que μ é o parâmetro da nossa função.
- ▶ A função $f(\mu)$ mede o quanto **perdemos** em representar y_i apenas usando μ .
- ▶ Funções perda muito populares são a **perda quadrática**, **perda absoluta**, **minmax** e a **cross entropia**.

Exemplo: Redução de dados

► Funções em R.

```
set.seed(123)
y <- rpois(10, 10)

fmu <- function(mu, y) {
  out <- sum((y - mu)^2)
  return(out)
}


fmu <- Vectorize(fmu, "mu")
fmu(mu = c(10, 12), y = y)

## [1] 117 161

f_prime <- function(mu, y) {
  out <- -2*sum(y-mu)
  return(out)
}
```


Exemplo: Redução de dados

- Graficamente, temos



Exemplo: Redução de dados

- Note que o **melhor** resumo dos dados de um número, corresponde ao ponto de mínimo da função $f(\mu) = \sum_{i=1}^n (y_i - \mu)^2$.
- Como o mínimo está relacionado com a derivada de $f(\mu)$?



Exemplo: Redução de dados

- ▶ No ponto de mínimo/máximo a inclinação da reta tangente a $f(\mu)$ é zero.
- ▶ Denote por $\hat{\mu}$ o ponto de mínimo/máximo de $f(\mu)$, então $f(\hat{\mu}) = 0$.
- ▶ Assim, temos (regra da cadeia!!)

$$\begin{aligned}f'(\mu) &= 2 \sum_{i=1}^n (y_i - \mu) \frac{d}{d\mu} (y_i - \mu) \\&= 2 \sum_{i=1}^n (y_i - \mu)(-1) = -2 \sum_{i=1}^n (y_i - \mu).\end{aligned}$$

Exemplo: Redução de dados

- Agora precisamos achar o ponto $\hat{\mu}$ tal que $f(\hat{\mu}) = 0$.

$$f'(\hat{\mu}) = 0$$

$$-2 \sum_{i=1}^n (y_i - \hat{\mu}) = 0$$

$$-\sum_{i=1}^n y_i + n\hat{\mu} = 0$$

$$n\hat{\mu} = \sum_{i=1}^n y_i$$

$$\hat{\mu} = \frac{\sum_{i=1}^n y_i}{n}.$$

Máximos e mínimos

- ▶ Sejam $f(x)$ uma função que admite segunda derivada no intervalo aberto I e $x \in I$.
 1. $f'(x) = 0$ e $f''(x) > 0$ é ponto de mínimo local.
 2. $f'(x) = 0$ e $f''(x) < 0$ é ponto de máximo local.
- ▶ $f''(x)$ denota a segunda derivada de $f(x)$, i.e. $\frac{\partial f'(x)}{\partial x}$.
- ▶ Em geral em estatística e técnicas padrões de *machine learning* a função objetivo/perda é criada para ter apenas um ponto de mínimo/máximo.
- ▶ Em situações patológicas, tais como falta de identificabilidade a função pode ter mais de um mínimo/máximo.

Funções de duas ou mais variáveis independentes

- ▶ Em geral uma função possui apenas uma variável dependente.
- ▶ Porém, pode ter duas ou mais variáveis independentes.
- ▶ Exemplo 1:

$$z = f(x, y) = \frac{x^2}{2^2} + \frac{y^2}{3^2}.$$

- ▶ Exemplo 2: Sejam y_i e x_i quantidades observadas. A equação da reta que relaciona x e y é dada por

$$y_i = f(\beta_0, \beta_1; x_i) = \beta_0 + \beta_1 x_i.$$

Derivadas parciais

- Para uma função $z = f(x, y)$, a derivada parcial de f em relação a x é representada por $\frac{\partial f}{\partial x}$, e é definida por

$$\frac{\partial f}{\partial x} = \lim_{h \rightarrow 0} \frac{f(x + h, y) - f(x, y)}{h},$$

desde que o limite exista.

- De forma similar, a derivada parcial de $f(x, y)$ em relação a y é representada por

$$\frac{\partial f}{\partial y} = \lim_{h \rightarrow 0} \frac{f(x, y + h) - f(x, y)}{h}.$$

- De forma geral, $\frac{\partial f(x)}{\partial x}$ é obtida derivando $f(x)$ considerando y fixo e vice-versa.

Gradiente e Hessiano

- ▶ O gradiente de uma função $f(x, y)$ é o vetor composto pelas derivadas primeira de $f(x, y)$ em relação a x e y , i.e.

$$\nabla f(x, y) = \left(\frac{\partial f(x, y)}{\partial x}, \frac{\partial f(x, y)}{\partial y} \right).$$

- ▶ O Hessiano de uma função $f(x, y)$ é a matrix

$$\mathbf{H} = \begin{pmatrix} \frac{\partial^2 f(x, y)}{\partial x^2} & \frac{\partial^2 f(x, y)}{\partial x \partial y} \\ \frac{\partial^2 f(x, y)}{\partial y \partial x} & \frac{\partial^2 f(x, y)}{\partial y^2} \end{pmatrix}.$$

- ▶ As definições se estendem naturalmente para mais de duas variáveis.
- ▶ Vamos revisar as ideias de vetores e matrizes (álgebra linear).

Expansão de funções em Série de Taylor

- ▶ Aproximação por Série de Taylor é fundamental em estatística e métodos numéricos.
- ▶ É uma forma simples de obter o valor aproximado de uma função perto de um ponto conhecido x_0 .
- ▶ Dada uma função $f(x)$ derivável $(n + 1)$ vezes em um intervalo contendo um ponto $x = x_0$, temos

$$\begin{aligned} f(x) = & f(x_0) + (x - x_0) \frac{df(x)}{dx} \Big|_{x=x_0} + \frac{(x - x_0)^2}{2!} \frac{d^2f(x)}{dx^2} \Big|_{x=x_0} + \\ & \dots + \frac{(x - x_0)^n}{n!} \frac{d^nf(x)}{dx^n} \Big|_{x=x_0} + R_n(x). \end{aligned}$$

- ▶ Aproximação similar é possível para funções com duas ou mais variáveis.


Expansão em série de Taylor

- Considere a seguinte função

$$f(\mu) = 2 \left(10 \log \frac{10}{\mu} - 10 + \mu \right).$$

Aproxime ao redor do ponto $\mu_0 = 10$.

```
f <- function(mu) {  
  out <- 2*(10*log(10/mu) - 10 + mu)  
  return(out)  
}  
  
plot(f, 0, 50, ylab = expression(f(mu)), xlab = expression(mu))
```



Expansão em série de Taylor

- Primeira derivada

$$f'(\mu) = 2 \left(1 - \frac{10}{\mu} \right).$$

- Segunda derivada

$$f''(\mu) = \frac{20}{\mu^2}.$$

- Aproximação em série de Taylor (segunda ordem) ao redor de μ_0 .

$$f(\mu) \approx f(\mu_0) + (\mu - \mu_0)f'(\mu = \mu_0) + \frac{(\mu - \mu_0)^2}{2!}f''(\mu = \mu_0).$$

Expansão em série de Taylor

► Aproximação de Taylor (genérica)

```
taylor_ap <- function(mu, mu0, f, f_prime, f_dprime) {  
  app <- f(mu = mu0) + (mu - mu0)*f_prime(mu = mu0) +  
    (((mu - mu0)^2)/(2))*f_dprime(mu = mu0)  
  return(app)  
}
```

► Derivadas

```
f_prime <- function(mu) {2*(1- 10/mu)}  
f_dprime <- function(mu) {20/mu^2}
```

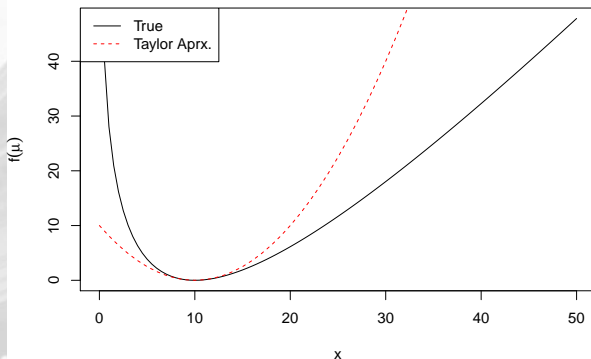
► Aproximando a função

```
taylor_ap(mu = c(9,10,11), mu0 = 10, f = f,  
  f_prime = f_prime, f_dprime = f_dprime)  
## [1] 0.1 0.0 0.1
```

Expansão em série de Taylor

► Graficamente, temos


```
plot(f, 0, 50, ylab = expression(f(mu)), xlab = "x")  
lines(0:50, taylor_ap(mu = 0:50, mu0 = 10, f = f, f_prime = f_prime,  
f_dprime = f_dprime), col = "red", lty = 2)  
legend("topleft", legend = c("True", "Taylor Aprx."), lty = c(1,2), col = c(1,2))
```



Expansão em série de Taylor

► Graficamente, temos

```
plot(f, 0, 50, ylab = expression(f(mu)), xlab = "x")
lines(0:50, taylor_ap(mu = 0:50, mu0 = 5, f = f, f_prime = f_prime,
                      f_dprime = f_dprime), col = "red", lty = 2)
lines(0:50, taylor_ap(mu = 0:50, mu0 = 15, f = f, f_prime = f_prime,
                      f_dprime = f_dprime), col = 3, lty = 3, lwd = 3)
legend("topleft", legend = c("True", "Taylor (mu0 = 5)", "Taylor (mu0 = 15)"),
      lty = c(1,2,3), col = c(1,2,3), lwd = c(1,1,3))
```



Exemplo - Regressão linear simples

- ▶ Seja $y_i (i = 1, \dots, n)$ observações de alguma variável de interesse.
- ▶ Seja x_i uma outra variável que queremos relacionar com y_i através de uma reta, i.e.

$$y_i = \beta_0 + \beta_1 x_i.$$


- ▶ Problema: Encontrar β_0 e β_1 tal que

$$SQ = f(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2,$$

seja a menor possível.

Exemplo - Regressão linear simples

- Graficamente, temos



Como encontrar β_0 e β_1 que minimizam a SQ?

► Abordagem 1

1. Obter o vetor gradiente

$$\nabla f(\beta_0, \beta_1) = \left(\frac{\partial f(\beta_0, \beta_1)}{\partial \beta_0}, \frac{\partial f(\beta_0, \beta_1)}{\partial \beta_1} \right).$$

2. Encontrar $\hat{\beta}_0$ e $\hat{\beta}_1$ tal que

$$\nabla f(\hat{\beta}_0, \hat{\beta}_1) = \mathbf{0}.$$

- Abordagem 2 - Obter a derivada analiticamente, mas resolver o sistema numericamente.
- Abordagem 3 - Obter a derivada e resolver o sistema numericamente.
- Abordagem 4 - Usar um algoritmo de otimização genérico.

Vetor gradiente

- ▶ Chame $y_i - (\beta_0 + \beta_1 x_i) = \epsilon_i$.
- ▶ Chame $\beta_0 + \beta_1 x_i = \mu_i$.
- ▶ Assim,

$$\nabla f(\beta_0, \beta_1) = \left(\frac{\partial f(\beta_0, \beta_1)}{\partial \epsilon_i} \frac{\partial \epsilon_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \beta_0}, \frac{\partial f(\beta_0, \beta_1)}{\partial \epsilon_i} \frac{\partial \epsilon_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \beta_1} \right).$$

onde

$$\frac{\partial f(\beta_0, \beta_1)}{\partial \epsilon_i} = \frac{\partial}{\partial \epsilon_i} \sum_{i=1}^n \epsilon_i^2 = 2 \sum_{i=1}^n \epsilon_i.$$

$$\frac{\partial \epsilon_i}{\partial \mu_i} = \frac{\partial}{\partial \mu_i} (y_i - \mu_i) = -1.$$

$$\frac{\partial \mu_i}{\partial \beta_0} = \frac{\partial}{\partial \beta_0} \beta_0 + \beta_1 x_i = 1.$$

$$\frac{\partial \mu_i}{\partial \beta_1} = \frac{\partial}{\partial \beta_1} \beta_0 + \beta_1 x_i = x_i$$

Vetor gradiente

- Vetor gradiente,

$$\begin{aligned}\nabla f(\beta_0, \beta_1) &= \left(-2 \sum_{i=1}^n \epsilon_i(1); -2 \sum_{i=1}^n \epsilon_i x_i \right) \\ &= \left(-2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i); -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) x_i \right).\end{aligned}$$

- Resolver o sistema de equações:

$$-2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad (1)$$

$$-2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i = 0 \quad (2)$$

Resolvendo o sistema de equações

- Pela Eq. (1) temos,

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}. \quad (3)$$

- Substituindo Eq.(3) em Eq. (2) e resolvendo em $\hat{\beta}_1$, temos

$$\hat{\beta}_1 = \frac{\bar{y} \sum_{i=1}^n x_i - \sum_{i=1}^n y_i x_i}{\bar{x} \sum_{i=1}^n x_i - \sum_{i=1}^n x_i^2}.$$

Implementação em R

► Simulando um conjunto de dados

```
set.seed(123)
b0 = 10
b1 = 5
x <- seq(0,10, l = 20)
mu <- b0 + b1*x
y <- rnorm(20, mean = mu, sd = 5)
head(cbind(y, x))

##           y           x
## [1,]  7.197622 0.0000000
## [2,] 11.480691 0.5263158
## [3,] 23.056699 1.0526316
## [4,] 18.247279 1.5789474
## [5,] 21.172754 2.1052632
## [6,] 31.733220 2.6315789


b1 <- (mean(y)*sum(x) - sum(y*x))/(mean(x)*sum(x) - sum(x^2))
b0 <- mean(y) - b1*mean(x)
c(b0,b1)

## [1] 11.470239  4.847576


# Conferindo
coef(lm(y ~ x))

## (Intercept)           x
##    11.470239    4.847576
```

Visualizando a reta ajustada



Visualizando a superfície objetivo



Discussão

- ▶ Derivadas são essenciais em *data science*.
- ▶ Maximizar/Minimizar funções perda/objetivo.
- ▶ O cálculo é por vezes difícil e tedioso.
- ▶ Solução de sistemas lineares é tedioso quando possível.
- ▶ Álgebra linear ajuda a generalizar as soluções.
- ▶ Em situações mais gerais expressões analíticas não serão possíveis de obter.
- ▶ Métodos numéricos para resolução de sistema não-lineares.
- ▶ Métodos numéricos de otimização.



Integrais

Integral de uma função

- ▶ Integral indefinida: É o oposto ou inverso da derivada, também chamada de **antiderivada**.
- ▶ Sendo $g(x)$ a derivada de $f(x)$, então a antiderivada ou integral indefinida de $g(x)$ é $f(x)$, sendo escrita como:

$$f(x) = \int g(x)dx.$$

- ▶ Exemplo: $\int xdx = \frac{x^2}{2}$. Uma vez que,

$$\frac{\partial}{\partial x} \frac{x^2}{2} = \frac{2x^{2-1}}{2} = x.$$


Integral de uma função

- ▶ Integral definida I é denotado por

$$I = \int_a^b f(x)dx.$$

- ▶ A integral é um número, e existe em um intervalo fechado $[a, b]$.
- ▶ Considere uma função $f(x)$ definida e contínua no intervalo $[a, b]$.
- ▶ O domínio de $f(x)$ pode ser dividido em n subintervalos definidos por $\Delta x_i = x_{i+1} - x_i$, onde $i = 1, \dots, n$.
- ▶ Soma de Riemann


$$\sum_{i=1}^n f(c_i) \Delta x_i$$

onde c_i é um número pertencente ao subintervalo $[x_i, x_{i+1}]$. 

Integral definida


- A integral definida é obtida como o limite da soma de Riemann quando a largura de todos os subintervalos de $[a, b]$ tende a zero:

$$I = \int_a^b f(x)dx = \lim_{\Delta x_i \rightarrow 0} \sum_{i=1}^n f(c_i)\Delta x_i.$$



Integral definida

- ▶ Aumentando o número de retângulos a área é melhor aproximada.
- ▶ Quando $n \rightarrow \infty$ ou $\Delta x_i \rightarrow 0$ a soma de Riemann corresponde a área abaixo da curva $f(x)$.



- ▶ Podemos facilmente imitar essa ideia numericamente em R.


Soma de Riemann

► Função para calcular a soma de Riemann.

```
soma_riemann <- function(n, a, b, fx, ...) {  
  intervalos <- seq(a, b, length = n)  
  ci <- c()  
  soma <- c()  
  for(i in 1:c(n-1)) {  
    Deltai <- (intervalos[i+1] - intervalos[i]) # Tamanho do intervalo  
    ci[i] <- (intervalos[i+1] + intervalos[i])/2 # Ponto central do intervalo  
    soma[i] <- fx(ci[i])*Deltai # Cada elemento da soma  
  }  
  return(sum(soma))  
}  
soma_riemann <- Vectorize(soma_riemann, "n")
```

Soma de Riemann

- Calculando a área abaixo da curva $f(x) = x^2$ em $[1, 2]$.



- Valor aproximado com $n = 100$.

```
soma_riemann(n = 100, a = 1, b = 2, fx = fx)
```

```
## [1] 2.333325
```


Teorema fundamental do cálculo

- ▶ Se uma função $f(x)$ é contínua ao longo do intervalo $[a, b]$ e $F(x)$ é a antiderivada de $f(x)$ ao longo desse mesmo intervalo, então

$$\int_a^b f(x)dx = F(b) - F(a).$$

- ▶ Existem tabelas de antiderivadas.
- ▶ Por exemplo, sendo n um natural ($n \neq -1$) temos

$$\int x^n dx = \frac{x^{(n+1)}}{n+1}.$$

- ▶ Assim, temos

$$\int_1^2 x^2 dx = F(2) - F(1) = \frac{x^3}{3} \Big|_{x=1}^{x=2} = \frac{8}{3} - \frac{1}{3} = \frac{7}{3} = 2.33 \dots$$

Propriedades e Regras básicas de Integração

- ▶ Sejam $f(x)$ e $g(x)$ funções contínuas em um certo intervalo e k uma constante. São válidas as propriedades:

1. $\int k f(x) dx = k \int f(x) dx.$
2. $\int [f(x) + g(x)] dx = \int f(x) dx + \int g(x) dx.$
3. $\int f'(x) g(x) dx = f(x) g(x) - \int f(x) g'(x) dx.$

- ▶ Regras básicas de integração:

1. $\int k dx = kx + c.$
2. $\int x^n dx = \frac{x^{n+1}}{n+1}.$
3. $\int \frac{1}{x} dx = \ln |x| + c.$
4. $\int \exp x dx = \exp x + c.$
5. $\int a^x dx = \frac{a^x}{\ln(a)} + c.$

- ▶ Ver tabela no material suplementar.
- ▶ Lista de exercícios.

Discussão

- ▶ Integrais são extremamente úteis para obter alguns resultados teóricos em probabilidade.
- ▶ Técnicas (básicas) de modelagem estatística e *machine learning* não usam integrais diretamente.
- ▶ Em geral integrais são mais difíceis de calcular do que derivadas.
- ▶ É possível estender a ideia de integrais para funções com duas ou mais variáveis de forma análoga feita para derivadas.
- ▶ Integrais em alta dimensão são extremamente difíceis de calcular e/ou aproximar numericamente.